```
In [ ]: # import Library
import pandas as pd
import numpy as np
df = pd.read_csv('./data/BL-Flickr-Images-Book.csv')
df.head()
```

]:	ldentitier		Edition Statement			Publisher	Title	Author	Con	
	0	206	NaN	London	1879 [1878]	S. Tinsley & Co.	Walter Forbes. [A novel.] By A. A	A. A.		
	1	216	NaN	London; Virtue & Yorston	1868	Virtue & Co.	All for Greed. [A novel. The dedication signed	A., A. A.	BU Pau	
	2	218	NaN	London	1869	Bradbury, Evans & Co.	Love the Avenger. By the author of "All for Gr	A., A. A.	BU Pau	
	3	472	NaN	London	1851	James Darling	Welsh Sketches, chiefly ecclesiastical, to the	A., E. S.	А	
	4	480	A new edition, revised, etc.	London	1857	Wertheim & Macintosh	[The World in which I live, and my place in it	A., E. S.	Jo	
				atement','Co ce=True, axi		nor','Corpo	orate Contrib	utors','	Form	
:	df	.head()								

Out[ ]:	ldentifier F		Place of Publication	Date of Publication	Publisher	Title	Author	Flickr
	0	206	London	1879 [1878]	S. Tinsley & Co.	Walter Forbes. [A novel.] By A. A	A. A.	http://www.flickr./photos/britishlib
	1	216	London; Virtue & Yorston	1868	Virtue & Co.	All for Greed. [A novel. The dedication signed	A., A. A.	http://www.flickr./photos/britishlib
	2	218	London	1869	Bradbury, Evans & Co.	Love the Avenger. By the author of "All for Gr	A., A. A.	http://www.flickr./photos/britishlib
	3	472	London	1851	James Darling	Welsh Sketches, chiefly ecclesiastical, to the	A., E. S.	http://www.flickr./photos/britishlib
	4	480	London	1857	Wertheim & Macintosh	[The World in which I live, and my place in it	A., E. S.	http://www.flickr./ /photos/britishlib

Dari script di atas, apa yang akan terjadi? Berikan penjelasan! Jawab:

Jadi pada fungsi di atas akan menghapus column

Flickr URI	Author	Title	Publisher	Date of Publication	Place of Publication	Out[ ]:		
						Identifier	Ident	
http://www.flickr.com /photos/britishlibrary /ta	A. A.	Walter Forbes. [A novel.] By A. A	S. Tinsley & Co.	1879 [1878]	London	206		
http://www.flickr.com /photos/britishlibrary /ta	A., A. A.	All for Greed. [A novel. The dedication signed	Virtue & Co.	1868	London; Virtue & Yorston	216		
http://www.flickr.com /photos/britishlibrary /ta	A., A. A.	Love the Avenger. By the author of "All for Gr	Bradbury, Evans & Co.	1869	London	218		
http://www.flickr.com /photos/britishlibrary /ta	A., E. S.	Welsh Sketches, chiefly ecclesiastical, to the	James Darling	1851	London	472		
http://www.flickr.com /photos/britishlibrary /ta	A., E. S.	[The World in which I live, and my place in it	Wertheim & Macintosh	1857	London	480		

# Silahkan coba script di atas dan apakah identifier berhasil menjadi index?

Jawab:

ya kolum indentifier berhasil menjadi index

```
Out[]: Identifier
        1905
                       1888
              1839, 38-54
         1929
                       1897
         2836
         2854
                       1865
         2956
                   1860-63
         2957
                        1873
         3017
                        1866
                        1899
         3131
         4598
                        1814
         4884
                        1820
        Name: Date of Publication, dtype: object
In [ ]: extr = df['Date of Publication'].str.extract(r'^(\d{4})', expand=False)
        extr.head()
Out[]: Identifier
         206
               1879
         216
                1868
         218
               1869
         472
               1851
         480
               1857
        Name: Date of Publication, dtype: object
```

### Silahkan ikuti script di atas dan amati serta berikan penjelasan mengenani hasil yang didapat.

Jawab:

berfungsi untuk mengambil data tahun pada kolom Date of Publication

```
In [ ]: |df['Date of Publication'] = pd.to_numeric(extr)
        df['Date of Publication'].dtype
Out[ ]: dtype('float64')
In [ ]: df['Place of Publication'].head(10)
Out[]: Identifier
         206
                                               London
                            London; Virtue & Yorston
         216
         218
                                               London
         472
                                               London
         480
                                               London
         481
                                               London
         519
                                               London
         667
                 pp. 40. G. Bryan & Co: Oxford, 1898
         874
                                              London]
         1143
                                               London
        Name: Place of Publication, dtype: object
In [ ]: |pub = df['Place of Publication']
        london = pub.str.contains('London')
        oxford = pub.str.contains('Oxford')
```

### Silahkan ikuti script di atas, dan berikan penjelasan apa yang terjadi!

#### Jawab:

berfungsi untuk mengambil data tahun pada kolom Date of Publication berdasarkan regex yang di tentukan np.where

berfungsi untuk mengganti '-' dengan ' ' pada kolom Date of Publication

```
In [ ]: |university_towns = []
         with open('./data/university_towns.txt') as file:
             for line in file:
                 if '[edit]' in line:
                     state = line
                 else:
                     university_towns.append((state, line))
         university_towns[:5]
Out[]: [('Alabama[edit]\n', 'Auburn (Auburn University)[1]\n'),
          ('Alabama[edit]\n', 'Florence (University of North Alabama)\n'),
          ('Alabama[edit]\n', 'Jacksonville (Jacksonville State University)[2]\n'),
          ('Alabama[edit]\n', 'Livingston (University of West Alabama)[2]\n'),
          ('Alabama[edit]\n', 'Montevallo (University of Montevallo)[2]\n')]
In [ ]: | towns_df = pd.DataFrame(university_towns, columns=['State', 'RegionName'])
         towns_df.head()
Out[ ]:
                     State
                                                        RegionName
         0 Alabama[edit]\n
                                        Auburn (Auburn University)[1]\n
           Alabama[edit]\n
                                Florence (University of North Alabama)\n
           Alabama[edit]\n Jacksonville (Jacksonville State University)[2]\n
           Alabama[edit]\n
                             Livingston (University of West Alabama)[2]\n
           Alabama[edit]\n
                               Montevallo (University of Montevallo)[2]\n
```

# Silahkan ikuti script di atas dan jelaskan apa hasil dari script tersebut.

### Jawab:

membaca file "university\_towns.txt" dan membentuk daftar university\_towns. Dalam loop, kode memeriksa apakah baris berisi "[edit]". Jika ya, itu dianggap sebagai negara bagian. Jika tidak, baris ditambahkan ke daftar sebagai kota perguruan tinggi dengan negara bagian terakhir yang terdeteksi. Hasilnya adalah daftar tupel yang berisi pasangan negara bagian dan nama kota perguruan tinggi. Baris terakhir menampilkan lima entri pertama dalam daftar sebagai pemantauan.

towns\_df membuat DataFrame dari university\_towns dengan kolom 'State' dan 'RegionName'. head() menampilkan lima baris pertama, memudahkan pemeriksaan struktur dan isi DataFrame.

```
In [ ]: def get_citystate(item):
    if ' (' in item:
        return item[:item.find(' (')]
    elif '[' in item:
        return item[:item.find('[')]]
    else:
        return item

towns_df = towns_df.applymap(get_citystate)
To [ ]: towns_df_boad()
```

In [ ]:	towns_df.head()
---------	-----------------

Out[]:		State	RegionName
	0	Alabama	Auburn
	1	Alabama	Florence
	2	Alabama	Jacksonville
	3	Alabama	Livingston
	4	Alabama	Montevallo

## Silahkan ikuti script di atas dan berikan penjelasan mengenai hasilnya!

#### Jawab:

Fungsi get\_citystate memproses setiap elemen DataFrame towns\_df. Jika terdapat ' (' atau '[', hanya bagian sebelumnya yang diambil. Metode applymap memanggil fungsi ini pada setiap sel, membersihkan data dari informasi tambahan.

Out[]:		0	1	2	3	4	5	6	7	8	9		10	1	1 12	2	13	1
	0	NaN	? Summer	01 !	02 !	03	Total	? Winter	01	02 !	03 !	IO	tal	Game	? 0°		02 !	С
	1	Afghanistan (AFG)	13	0	0	2	2	0	0	0	0		0	1	3 (	)	0	
	2	Algeria (ALG)	12	5	2	8	15	3	0	0	0		0	1	5 !	5	2	
	3	Argentina (ARG)	23	18	24	28	70	18	0	0	0		0	4	1 18	3	24	2
	4	Armenia (ARM)	5	1	2	9	12	6	0	0	0		0	1	1	l	2	
In [ ]:	<pre>olympics_df = pd.read_csv('./data/olympics.csv', header=1) olympics_df.head()</pre>																	
Out[ ]:		Unnamed: 0	? Summer	01 !	02 !	03 !	Total	Winte	? 0 r !.			03 !.1	Tot	al.1	Game	?	01 !.2	!
	0	Afghanistan (AFG)	13	0	0	2	2	(	)	0	0	0		0	1	3	0	_
	1	Algeria (ALG)	12	5	2	8	15	3	3	0	0	0		0	1	5	5	
	2	Argentina (ARG)	23	18	24	28	70	18	8	0	0	0		0	4	1	18	
	3	Armenia (ARM)	5	1	2	9	12		6	0	0	0		0	1	1	1	
	4	Australasia (ANZ) [ANZ]	2	3	4	5	12	. (	0	0	0	0		0		2	3	

# Silahkan amati dan jelaskan perbedaan dari gambar sebelumnya!

### Jawab:

Pada tabel sebelumnya header column nya berupa index, sedangkan pada tabel ini header column nya berupa nama column

In [ ]: olympics\_df.head()

Out[ ]:		Country	Summer Olympics	Gold	Silver	Bronze	Total	Winter Olympics	Gold.1	Silver.1	Bronz
	0	Afghanistan (AFG)	13	0	0	2	2	0	0	0	
	1	Algeria (ALG)	12	5	2	8	15	3	0	0	
	2	Argentina (ARG)	23	18	24	28	70	18	0	0	
	3	Armenia (ARM)	5	1	2	9	12	6	0	0	
	4	Australasia (ANZ) [ANZ]	2	3	4	5	12	0	0	0	

## Ikuti script di atas dan berikan penjelasan mengenai hasilnya!

### Jawab:

mengganti nama kolom pada DataFrame olympics\_df menggunakan variable new\_names. Operasi ini memberi label kolom-kolom dengan nama yang lebih deskriptif untuk analisis Olimpiade, dan inplace=True mengubah DataFrame secara langsung.